

SECONDARY LANGUAGE VERSION:

A Comparative Study of Classical and Transformer-Based Models for Phishing Email Detection

Bachelor Semester Project 6

João Bernardo SOUSA FARIA
Student ID: 0232421751
University of Luxembourg
joao.sousa.003@student.uni.lu

Secondary Language:
French

Salima LAMSIYAH
Department of Computer Science
University of Luxembourg
salima.lamsiyah@uni.lu

Le projet a été développé par l'étudiant **João Bernardo Sousa Faria**, sous la supervision de **Salima Lamsiyah**.

Ce projet porte sur la **détection automatique de courriels de phishing à l'aide de méthodes de traitement automatique du langage naturel**. Le phishing est une menace notamment présente en cybersécurité, car il cherche à tromper les utilisateurs afin qu'ils cliquent sur des liens malveillants ou révèlent des informations sensibles. Dans ce travail, la détection du phishing est traitée comme une tâche de classification binaire, où chaque courriel est classé comme sûr ou comme phishing.

L'objectif principal est de comparer une approche classique avec une approche moderne basée sur les Transformers. Le modèle classique utilise **TF-IDF** avec une **régression logistique**, une méthode rapide, simple et interprétable. Le modèle moderne utilise BERT, qui peut prendre en compte le contexte des mots dans un courriel.

Le jeu de données principal a été nettoyé, filtré et dédupliqué avant l'entraînement. Après le prétraitement, il contenait 17 537 courriels. Les données ont été divisées en ensembles d'entraînement, de validation et de test. Le projet inclut aussi le réglage du seuil de décision, une variante avec pondération des classes et une analyse

d'explicabilité basée sur les coefficients de la régression logistique.

Les résultats montrent que les deux approches sont efficaces. Le meilleur modèle classique atteint une accuracy de **0.9814** et un score F1 phishing de **0.9752**. BERT obtient les **meilleurs résultats**, avec une accuracy de **0.9875** et un score F1 phishing de **0.9832**. Cependant, l'écart entre les deux modèles reste limité, ce qui montre que TF-IDF avec régression logistique demeure très compétitif.

Enfin, une expérience avec le benchmark DIFraud montre que les performances **diminuent** lorsque les modèles sont testés sur un autre jeu de données. Cela suggère que les modèles peuvent apprendre certaines caractéristiques propres aux données d'entraînement. En résumé, BERT offre les meilleures performances, mais TF-IDF avec régression logistique reste une solution rapide, interprétable et efficace. Le projet atteint ainsi ses objectifs principaux:

- comparer deux approches de classification, analyser leurs résultats;
- étudier leur capacité de généralisation pour la détection des courriels de phishing.